

# Reconhecimento de imagens de possíveis áreas de assoreamento com deep learning

João V. S. Rocha<sup>1</sup>  
joaovic.rocha3@gmail.com

<sup>1</sup>Instituto de Computação – Universidade Federal de Mato Grosso (UFMT)

**Abstract.** *This research aims to develop a convolutional neural network for the classification of images of silting regions, classifying them into regions that have silting and those that do not. We use deep learning techniques with data augmentation, where we seek to potentiate and diversify the amount and possibility of image sizes and contrasts so that there is training with satisfactory results so that, finally, classify and help to discover the regions affected by siltation.*

**Resumo.** *Esta pesquisa tem como objetivo o desenvolvimento de uma rede neural convolucional para a classificação de imagens de regiões com assoreamento, classificando-as em regiões que possuem assoreamento e que não possuem. Utiliza-se técnicas de deep learning com data augmentation, onde se busca potencializar e diversificar a quantidade e possibilidade de tamanhos e contrastes de imagens para que haja um treinamento com resultados satisfatórios para que por fim, classifique e ajude na descoberta de regiões acometidas pelo assoreamento.*

## 1. Introdução

Assoreamento é o acúmulo de detritos como areia, terra, entulhos, levando-se assim a se acumular no fundo de rios e lagoas interferindo na topografia desses afluentes, assim, diminuindo-se a capacidade hídrica e podendo futuramente causar catástrofes como por exemplo, alagamentos.

A caracterização de um assoreamento se dá por alguns fatores, regiões que possuem rios com encostas com erosão, grandes rios que possuem bancos de areia ou terra limitando o seu nível de profundidade.

Devido a isto, essa pesquisa tem como objeto o reconhecimento de áreas com sedimentação e/ou erosão em rios com o objetivo de que, com imagens, possa-se aplicar algoritmos de inteligência artificial para reconhecer especificamente áreas acometidas por assoreamento, assim então, criando uma rede de treinamento para a inteligência artificial.

## 2. Metodologia

Nesta seção serão descritos os métodos utilizados para a realização desta pesquisa, as técnicas, os dados e as classes usados para o treinamento da inteligência artificial.

### 2.1. Técnicas para o treinamento

Nesta pesquisa foram utilizadas as redes neurais convolucionais que trazem ótimos resultados quando se diz respeito a tratamento de imagens virtuais. Foi usado também um modelo sequencial (Sequential model), o qual treina o modelo aplicando uma pilha linear de camadas.

## **2.2. Tecnologias**

Para o desenvolvimento desse modelo foi necessário o uso de algumas ferramentas e linguagem de programação específica para tratar os dados para o treinamento da inteligência artificial. A linguagem de programação escolhida foi o Python. As bibliotecas para a linguagem foram Tensorflow, Keras, Numpy, Time e Matplotlib. Vale ressaltar o uso do gerenciador de pacotes conda, o qual foi usado para instalação de algumas dessas bibliotecas citadas.

## **2.3. Dados e Classes**

Buscou-se fotos de regiões acometidas pelo assoreamento a partir do pressuposto geral da formação - regiões que possuem rios com encostas com erosão, grandes rios que possuem bancos de areia ou terra limitando o seu nível de profundidade, assim como já foi citado na introdução.

Para o conjunto onde não se caracteriza assoreamento, buscou-se imagens de ambientes que possam se parecer com imagens de assoreamento, exemplo: ilhas, rios, erosão e depressões isoladas.

A obtenção de imagens para o treinamento e validação dessa inteligência artificial foi realizada com o apoio do script google-download-images, o qual aplica filtros de busca como palavras-chave e sites específicos para busca. Os dois filtros foram usados.

Então, como visto, a base de dados foi dividida de forma binária para a classificação: uma classe onde contém imagens de assoreamento e outra onde contém imagens que não caracterizam assoreamento.

## **2.4. Rede neural Convolutacional e o Modelo Sequencial**

Com o treinamento através de redes convolucionais, pode-se extrair informações de imagens e definir os filtros de aprendizado, transformar a imagem em um vetor de características e por fim aplicar sequência de convoluções. Já com o modelo Sequencial, aplica-se os filtros de convoluções, ativação e pooling.

## **2.5. Transfer Learning**

Transfer learning é um método de machine learning, o qual reutiliza um modelo que já foi treinado para alguma tarefa. Na seção a seguir iremos obter resultados do transfer learning aplicado aos dados do treinamento, utilizando as camadas DenseNet, Inceptionv3, Resnet, VGG e Xception.


## **3. Resultados**

Nesta seção serão apresentados os resultados do treinamento da rede. Testes foram realizados com menos imagens e menos épocas também, além do número de imagens por época. Foi observada uma porcentagem boa para validação, porém, com a perspectiva de que a rede poderia não estar generalizando e não aprendendo mais, incrementou-se o número de imagens e no conjunto de imagens de validação foram adicionadas imagens que não estavam presentes no conjunto de treinamento.

Para esta rede, foram utilizadas 100 épocas, e em cada uma foram definidos que seriam treinados um total de 30 imagens. Esta rede foi treinada com 992 imagens para o conjunto

de treinamento e 112 para o conjunto de teste. O treinamento foi realizado com as imagens com a resolução de 299x299 pixels definido no algoritmo, já que o conjunto possuía imagens de diversos tamanhos. Com essa configuração, foi obtido uma acurácia por volta de 93 por cento em média na validação.

### 3.1. Acurácia




**Figura 1. Gráfico de acurácia do modelo**

O gráfico de acurácia (Figura 1) apresenta treinamento e validação seguindo um ritmo semelhante de crescimento, onde a acurácia de validação alcançou pontos mais altos em certas épocas, chegando a mais que 94 por cento, o que pode ser considerado um resultado satisfatório.

### 3.2. Loss (Perda)

O gráfico de perda (Figura 2) nos apresenta uma perda linear, não alcançando níveis altos. Porém, comparando com a perda de dados na validação, percebe-se uma certa discrepância em épocas do treinamento. Observa-se que após essa diferença, o gráfico nos mostra o começo de uma normalização, concluindo assim que estamos evitando o overfitting dos dados.



**Figura 2. Gráfico de perda do modelo**

### 3.3. Transfer Learning

Neste caso específico, o transfer learning não foi eficaz pelo uso de classes binárias e os modelos usados oferecem muitas camadas, o que o torna muito complexo para rede. O resultado de todos os modelos usados ficaram na mesma média de 50 por cento, sendo assim ineficaz.

### 4. Considerações finais

Para esta pesquisa, pode-se concluir que o objetivo foi alcançado, a partir do momento em que se foi obtido um resultado satisfatório na validação dos dados. Foi observado um pico na perda dos dados, mas nada relevante o suficiente. Para trabalhos futuros, deve-se buscar por mais imagens para a classe de assoreamento, assim permanecendo em níveis baixos de perda.

### 5. Referências

CABRAL, João Batista Pereira. Estudo do processo de assoreamento em reservatórios. Caminhos de Geografia, 2005, 6.14.

Sequential mode. Keras. Disponível em: <https://keras.io/getting-started/sequential-model-guide/>; Acesso em: 30 de set. 2019.

Estudo de Caso: Avaliação de Impactos Ambientais no Horto Florestal – Tote Garcia em Cuiabá – Mato Grosso; Autores: Ferreira et al. v. 21, n. 2, 2017.

Google Images Download. Github. Disponível em: <https://github.com/hardikvasa/google-images-download>; Acesso em: 14 de ago. 2019.